# RAN

Isaac Kinane

February 2026

**Abstract**

Ce document présente la formalisation mathématique des (RAN). Nous partons de l'intuition des mécanismes d'attention pour dériver une architecture basée sur des formes quadratiques, en introduisant l'hypothèse de diagonalisation mutuelle pour réduire la complexité paramétrique.

## 1 Introduction et Intuition

Le problème actuel est que les KAN constituent le modèle explicable state-of-the-art compatible avec la rétropropagation. Cependant, leur principal inconvénient réside dans leur coût computationnel élevé. En effet, ils reposent sur des splines, ce qui rend leur optimisation sur GPU peu efficace.

Nous proposons un modèle alternatif explicable, dont le coût computationnel est significativement plus faible, proche de celui d'un MLP et pleinement compatible avec les architectures GPU.

Ce modèle conserve des performances comparables à celles des KAN et des MLP.

Nous nous appuyons sur le mécanisme d'attention (cf. Attention Is All You Need), défini par le produit $QK^\top$, où Q (Query) et K (Key) sont des projections linéaires des embeddings d'entrée. En développant, on obtient $QK^\top = (XW_Q)(XW_K)^\top = XW_QW_K^\top X^\top$, ce qui met en évidence une forme bilinéaire en X.

Considérons un modèle linéaire classique $y = \langle W, x\rangle$. L'objectif est de générer une fonction linéaire dépendante d'un contexte $c$. Si $W$ est généré par $c$ via une matrice $A$ telle que $c^TA = W^T$, alors :

$$y = (c^TA)x$$

Si nous fixons le contexte comme étant l'entrée elle-même ($c = x$), nous reconnaissons une application bilinéaire :

$$y = x^TAx$$

## 2 Dérivation Mathématique et Contraintes

Pour construire un réseau de neurones, nous souhaitons mettre cette opération en couche :

$$y = x^TB\left(x^TA_1x, x^TA_2x, \ldots, x^TA_nx\right)$$

Cependant, pour un réseau de taille moyenne, apprendre $N$ matrices $A_i$ distinctes de taille $N \times N$ engendre une explosion du nombre de paramètres ($O(N^3)$).

### 2.1 Contrainte 1 : Décomposition Spectrale

Pour réduire la complexité, nous supposons d'abord que chaque matrice $A$ est diagonalisable. En utilisant la décomposition spectrale, pour une matrice $A$ donnée :

$$y = x^TAx = \sum_k \lambda_k(x^Tp_k)(l_k^Tx)$$

où $l_k$ sont les vecteurs propres à gauche et $p_k$ les vecteurs propres à droite.

Ainsi, la couche devient une combinaison de termes spectraux :

$$y = x^T B \left( \dots, \sum_k \lambda_{i,k} (x^T p_{i,k})(l_{i,k}^T x), \dots \right)$$

### 2.2 Contrainte 2 : Diagonalisation Mutuelle

Même avec la décomposition spectrale, si chaque $A_i$ possède sa propre base de vecteurs propres, le modèle reste trop lourd. Nous imposons donc une **contrainte forte** : les matrices $A_i$ sont **mutuellement diagonalisables**. Cela signifie qu'elles partagent la même base de vecteurs propres ($p_k$ et $l_k$), et ne diffèrent que par leurs valeurs propres $\lambda_{i,k}$.

L'équation de la couche devient alors :

$$y = x^T A_2 \left( \sum_k \lambda_{1,k} (x^T p_k)(l_k^T x), \dots, \sum_k \lambda_{n,k} (x^T p_k)(l_k^T x) \right) \tag{1}$$

Cette contrainte permet une factorisation massive des paramètres. Si nous imposons de plus que $A$ soit une forme quadratique symétrique (où $p_k = l_k$), nous obtenons :

$$y = x^T A x = \sum_k \lambda_k (p_k^T x)^2$$

Sous forme matricielle, cette dérivation nous mène directement à la définition de la couche spectrale efficace présentée ci-dessous.

## 3 Définitions Formelles du Modèle

### 3.1 Couche Élémentaire (Spectral Quadratic Layer)

Sur la base de la dérivation précédente, nous définissons la couche $\Phi_l$ qui applique une projection commune (la base partagée), une élévation au carré, puis une recombinaison (les valeurs propres spécifiques à chaque neurone de sortie).

$$\Phi_l(\mathbf{x}) = \Lambda^{(l)} \left( W^{(l)} \mathbf{x} + \mathbf{b}^{(l)} \right)^{\odot 2} + \boldsymbol{\beta}^{(l)} \tag{2}$$

où :

- $W^{(l)}$ contient les vecteurs propres partagés (changement de base).
- $\Lambda^{(l)}$ contient les valeurs propres (poids de mélange).
- $\odot 2$ est l'activation quadratique issue de la forme $x^T A x$.

### 3.2 Architectures Profondes

#### 3.2.1 Réseau à 2 couches (Modèle Quartique - Degré 4)

$$F_\theta(\mathbf{x}) = \Lambda^{(2)} \left( W^{(2)} \left[ \Lambda^{(1)} \left( W^{(1)} \mathbf{x} + \mathbf{b}^{(1)} \right)^{\odot 2} + \boldsymbol{\beta}^{(1)} \right] + \mathbf{b}^{(2)} \right)^{\odot 2} + \boldsymbol{\beta}^{(2)} \tag{3}$$

Interprétation scalaire :

$$y = \sum_{k=1}^{d_2} \lambda_k^{(2)} \left( \sum_{j=1}^{d_1} \lambda_{k,j}^{(1)} (\mathbf{w}_j^\top \mathbf{x} + b_j)^2 + \beta_j^{(1)} \right)^2 + \beta^{(2)} \tag{4}$$

### 3.2.2 Propriété de croissance du degré

Le degré algébrique du polynôme représenté par le réseau croît exponentiellement avec la profondeur :

$$\deg(F) = 2^L \tag{5}$$

### 3.2.3 Propriété IFS (Iterated Function System)

Ce n'est pas seulement approximateur de fonction : c'est un générateur fractal. On peut y reconnaître l'ensemble de Mandelbrot, défini par :

$$z_{n+1} = z_n^2 + c, \quad z_0 = 0. \tag{6}$$

### 3.2.4 Phénomène de Runge

Alors que l'approximation polynomiale classique peut souffrir du phénomène de Runge, le comportement observé ici diffère sensiblement.

Le chaos éventuel est structuré par la propriété fractale du modèle. Par conséquent, les réseaux très profonds ne présentent pas de comportement chaotique non contrôlé.

Cette observation a été vérifiée empiriquement sur des réseaux profonds de 15 et 20 couches dans une tâche de Zero-shot.

# 4 Analyse Théorique

[Approximation Universelle] Soit $K \subset \mathbb{R}^n$ un ensemble compact. Soit $C(K, \mathbb{R})$ l'espace des fonctions continues sur $K$ muni de la norme uniforme $\|f\|_\infty = \sup_{x \in K} |f(x)|$.

La classe des fonctions $\mathcal{F}_{\text{DSN}}$ générées par un Deep Spectral Network est dense dans $C(K, \mathbb{R})$. C'est-à-dire :

$$\forall f \in C(K, \mathbb{R}), \quad \forall \epsilon > 0, \quad \exists F \in \mathcal{F}_{\text{DSN}} \quad \text{tel que} \quad \|F - f\|_\infty < \epsilon \tag{7}$$

Nous cherchons à démontrer que l'espace fonctionnel généré par le réseau DSN, noté $\mathcal{F}_{\text{DSN}}$, est dense dans $C(K, \mathbb{R})$.

La démonstration repose sur le théorème de **Stone-Weierstrass**. Ce théorème stipule que si une sous-algèbre $\mathcal{A}$ de $C(K, \mathbb{R})$ satisfait les propriétés suivantes :

1. $\mathcal{A}$ contient les fonctions constantes.
2. $\mathcal{A}$ sépare les points (pour tout $x \neq y$, il existe $f \in \mathcal{A}$ telle que $f(x) \neq f(y)$).
3. $\mathcal{A}$ est close sous l'addition et la multiplication.

Alors $\mathcal{A}$ est dense dans $C(K, \mathbb{R})$ pour la topologie de la convergence uniforme.

Nous allons montrer que $\mathcal{F}_{\text{DSN}}$ peut approximer arbitrairement tout polynôme multivarié. Comme l'ensemble des polynômes $\mathbb{R}[X_1, \ldots, X_n]$ satisfait les conditions de Stone-Weierstrass, il suffira de prouver que le DSN peut implémenter les opérations fondamentales de l'algèbre polynomiale.

**1. La Multiplication (via l'Identité de Polarisation)** La particularité du DSN est l'activation spectrale quadratique $z \mapsto z^2$. Pour réaliser le produit de deux valeurs scalaires $u, v$, nous utilisons l'identité de polarisation :

$$u \cdot v = \frac{1}{4}\left((u+v)^2 - (u-v)^2\right) \tag{8}$$

Cette opération est réalisable exactement par une couche DSN :

- La projection linéaire $W$ génère les combinaisons $h_1 = u + v$ et $h_2 = u - v$.
- L'activation élève au carré : $h_1^2 = (u+v)^2$ et $h_2^2 = (u-v)^2$.
- La couche de sortie $\Lambda$ effectue la somme pondérée avec les poids $\lambda_1 = \frac{1}{4}$ et $\lambda_2 = -\frac{1}{4}$.

**2. L'Identité et les Fonctions Affines** Pour construire des polynômes de degré impair (et pour séparer les points), le réseau doit pouvoir propager l'entrée $x$ sans l'élever au carré. Nous utilisons l'identité de polarisation appliquée à $x$ et à la constante 1 :

$$x = x \cdot 1 = \frac{1}{4}\left((x+1)^2 - (x-1)^2\right) \tag{9}$$

Ainsi, en ajustant les biais des neurones à $+1$ et $-1$, le DSN peut implémenter la fonction identité $x \mapsto x$.

**3. Sommes et Constantes**

- **Addition :** La linéarité des transformations $W$ et $\Lambda$ assure la clôture sous l'addition.
- **Constantes :** La fonction constante $c$ s'obtient trivialement (par exemple via $c \cdot (0+1)^2$).

**Conclusion** Puisque le réseau DSN peut implémenter l'addition, la multiplication, les constantes et la fonction identité, il peut construire tout polynôme multivarié $P(x) = \sum c_\alpha x^\alpha$. Par conséquent, $\mathcal{F}_{\text{DSN}}$ est un approximateur universel.

# 5 Résultats expérimentaux

## 5.1 GPT-2

Un GPT-2 de 5M paramètres entraîné sur *Tiny Shakespeare* atteint une loss d'entraînement de 1.45 avec l'architecture classique (MLP + cross-entropy). En remplaçant le MLP par un RAN, la loss obtenue est de 1.48, soit une différence faible.

Un GPT-2 de 50M paramètres entraîné sur *WikiText* converge vers une loss de validation standard. Aucune comparaison directe avec un GPT-2 classique de 50M n'a été réalisée.

## 5.2 Jeu de données Criteo CTR

Nous évaluons le modèle sur le jeu de données *Criteo CTR*, dont l'objectif est de prédire si un visiteur du site cliquera ou non sur une publicité.

Avec un nombre de paramètres équivalent, le MLP obtient une accuracy de 77.44 %, tandis que le modèle RAN atteint 77.84 %.

Les expériences ont été réalisées sur un sous-ensemble de 1M d'exemples, parmi l'ensemble total des données disponibles.

## 5.3 Régression symbolique

Détails du Modèle et Architecture

L'architecture du **DSN** utilisée pour cette extraction se compose des éléments suivants :

- **Couche d'entrée :** 2 neurones (variables $m$ et $v$).
- **Couche cachée :** 1 couche de 30 neurones.
- **Couche de sortie :** 1 neurone (prédiction de $E$).

Le modèle a été entraîné sur un jeu de **50 000 données**. Pour favoriser la parcimonie (sparsity) et faciliter l'extraction symbolique, une **pénalité L1** a été appliquée avec un coefficient hyperparamètre $\lambda = 0.1$.

### 5.3.1 Équation de base développée

L'expression polynomiale complète extraite directement du réseau avant filtrage est la suivante :

$$\begin{aligned} E(m,v) =& 5.62 \cdot 10^{-5} m^4 - 9.73 \cdot 10^{-7} m^3 v - 0.00222 m^3 - 0.0252 m^2 v^2 \\ &+ 1.81 \cdot 10^{-5} m^2 v + 0.0218 m^2 + 2.18 \cdot 10^{-5} m v^3 + 0.497 m v^2 \\ &+ 2.25 \cdot 10^{-5} m v + 0.00297 m + 0.00447 v^4 - 0.000211 v^3 \\ &+ 0.0336 v^2 + 1.43 \cdot 10^{-6} v + 0.000122 \end{aligned} \tag{10}$$

### 5.3.2 Équation avec seuil (Threshold = 0.05)

En appliquant un seuil de coupure de 0.05 sur la valeur absolue des coefficients, la majorité des termes bruités sont éliminés. On obtient alors une forme simplifiée qui capture l'essence physique du phénomène :

$$E(m,v) \approx 0.497 m v^2 \tag{11}$$

*Note : la formulation classique de l'énergie cinétique* $\frac{1}{2}mv^2$.

Table 1: Benchmark de Feynman (utilisé dans l'article original des KAN), validation croisée avec $k = 4$

| Diff. | Tâche | Modèle | MSE $\mu \pm \sigma$ | $R^2$ $\mu$ | MAE $\mu$ | Conv. | Params |
|---|---|---|---|---|---|---|---|
| **Easy** | I.6.2a Gaussienne | **RAN** | $\mathbf{0.0000 \pm 0.0000}$ | **1.000** | 0.0029 | ep4 | 149 |
| | | MLP | $0.0012 \pm 0.0009$ | 0.991 | 0.0220 | ep13 | 151 |
| | | KAN | $0.0017 \pm 0.0001$ | 0.986 | 0.0319 | ep5 | 159 |
| | I.18.4 Centre de masse | **RAN** | $\mathbf{0.0335 \pm 0.0062}$ | **0.993** | 0.1335 | ep11 | 137 |
| | | MLP | $0.1362 \pm 0.1428$ | 0.973 | 0.2290 | ep9 | 163 |
| | | KAN | $0.4188 \pm 0.0093$ | 0.918 | 0.4702 | ep5 | 169 |
| | I.26.2 Loi de Snell | **RAN** | $\mathbf{0.0007 \pm 0.0001}$ | **0.997** | 0.0170 | ep8 | 153 |
| | | KAN | $0.0017 \pm 0.0000$ | 0.994 | 0.0296 | ep5 | 167 |
| | | MLP | $0.0021 \pm 0.0010$ | 0.992 | 0.0315 | ep14 | 157 |
| | I.27.18 Lentille | **RAN** | $\mathbf{0.0001 \pm 0.0000}$ | **0.999** | 0.0083 | ep13 | 153 |
| | | MLP | $0.0035 \pm 0.0025$ | 0.969 | 0.0408 | ep16 | 157 |
| | | KAN | $0.0076 \pm 0.0005$ | 0.934 | 0.0619 | ep178 | 167 |
| | I.37.4 Interférences | **RAN** | $\mathbf{0.0013 \pm 0.0007}$ | **0.998** | 0.0238 | ep4 | 153 |
| | | KAN | $0.0090 \pm 0.0002$ | 0.987 | 0.0643 | ep6 | 167 |
| | | MLP | $0.0166 \pm 0.0073$ | 0.976 | 0.0916 | ep8 | 157 |
| | I.50.26 Oscil. Harmonique | **RAN** | $\mathbf{0.6515 \pm 0.0456}$ | **0.839** | 0.5821 | ep200 | 137 |
| | | MLP | $1.0943 \pm 0.4118$ | 0.747 | 0.6648 | ep200 | 163 |
| | | KAN | $1.8664 \pm 0.4993$ | 0.559 | 0.7723 | ep200 | 169 |
| | Pendule (Période) | **KAN** | $\mathbf{0.0022 \pm 0.0001}$ | **1.000** | 0.0296 | ep4 | 159 |
| | | RAN | $0.0042 \pm 0.0003$ | 0.999 | 0.0426 | ep4 | 149 |
| | | MLP | $0.0574 \pm 0.0516$ | 0.991 | 0.1539 | ep3 | 151 |
| | Carnot (Rendement) | **RAN** | $\mathbf{0.0000 \pm 0.0000}$ | **1.000** | 0.0021 | ep2 | 149 |
| | | MLP | $0.0069 \pm 0.0096$ | 0.701 | 0.0489 | ep56 | 151 |
| | | KAN | $0.0157 \pm 0.0088$ | 0.298 | 0.0926 | ep6 | 159 |
| **Med.** | I.12.1 Coulomb | **KAN** | $\mathbf{0.0089 \pm 0.0026}$ | **0.997** | 0.0515 | ep7 | 167 |
| | | RAN | $0.0145 \pm 0.0033$ | 0.996 | 0.0700 | ep5 | 153 |
| | | MLP | $0.0180 \pm 0.0075$ | 0.995 | 0.0689 | ep8 | 157 |
| | I.15.1 Contraction Lor. | **RAN** | $\mathbf{12.68 \pm 2.02}$ | **0.999** | 2.4082 | ep4 | 153 |
| | | KAN | $35.25 \pm 41.33$ | 0.997 | 3.6212 | ep8 | 167 |
| | | MLP | $48.73 \pm 45.21$ | 0.996 | 4.8851 | ep8 | 157 |
| | I.15.10 Lorentz (temps) | **KAN** | $\mathbf{0.0030 \pm 0.0007}$ | **1.000** | 0.0349 | ep5 | 167 |
| | | RAN | $0.0085 \pm 0.0021$ | 0.999 | 0.0659 | ep10 | 153 |
| | Entropie (Sackur-Tet.) | **RAN** | $\mathbf{2526 \pm 1071}$ | **0.999** | 33.18 | ep5 | 153 |
| | | KAN | $8165 \pm 4041$ | 0.997 | 53.39 | ep40 | 167 |
| | Kepler (3ème loi) | **MLP** | $\mathbf{0.0000 \pm 0.0000}$ | **1.000** | 0.0006 | ep4 | 151 |
| | | RAN | $0.0017 \pm 0.0020$ | 0.999 | 0.0273 | ep3 | 149 |
| **Hard** | III.4.32 Bose-Einstein | **RAN** | $\mathbf{0.0023 \pm 0.0003}$ | **0.998** | 0.0300 | ep7 | 149 |
| | Maxwell (Vitesses) | **KAN** | $\mathbf{0.7271 \pm 0.0968}$ | **0.827** | 0.3428 | ep200 | 167 |
| | Larmor (Puissance) | **MLP** | $\mathbf{0.0040 \pm 0.0018}$ | **1.000** | 0.0546 | ep3 | 151 |
| **V.H.** | III.9.52 Rabi | **RAN** | $\mathbf{0.0607 \pm 0.0041}$ | **0.346** | 0.1890 | ep200 | 161 |

## 5.4 Évaluation en situation Out-of-Distribution (OOD)

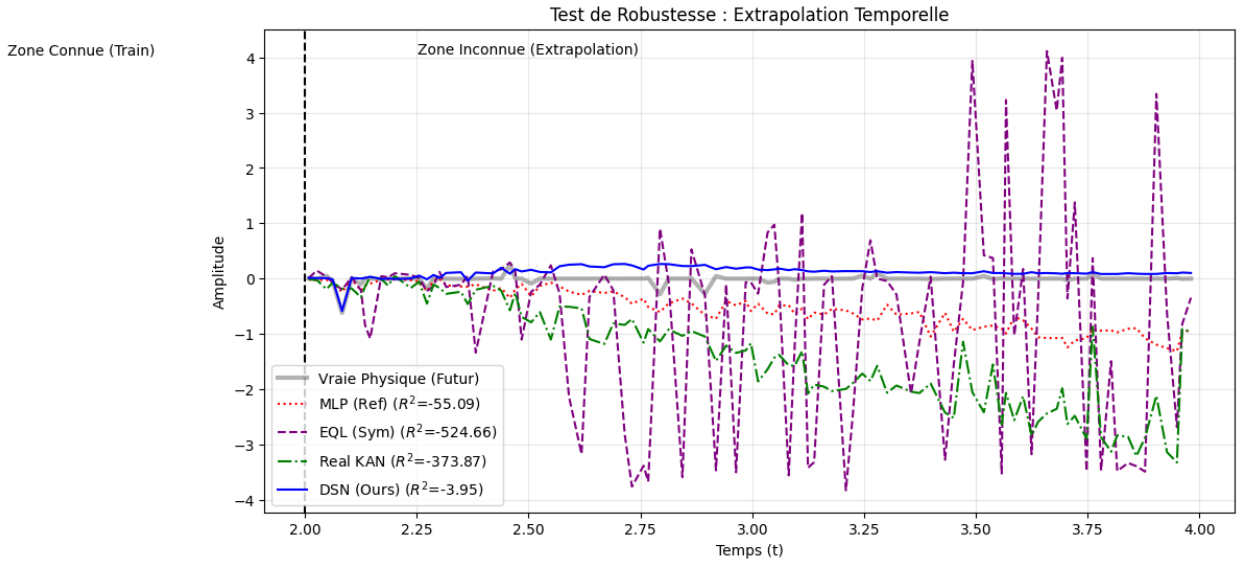



Figure 1: test1

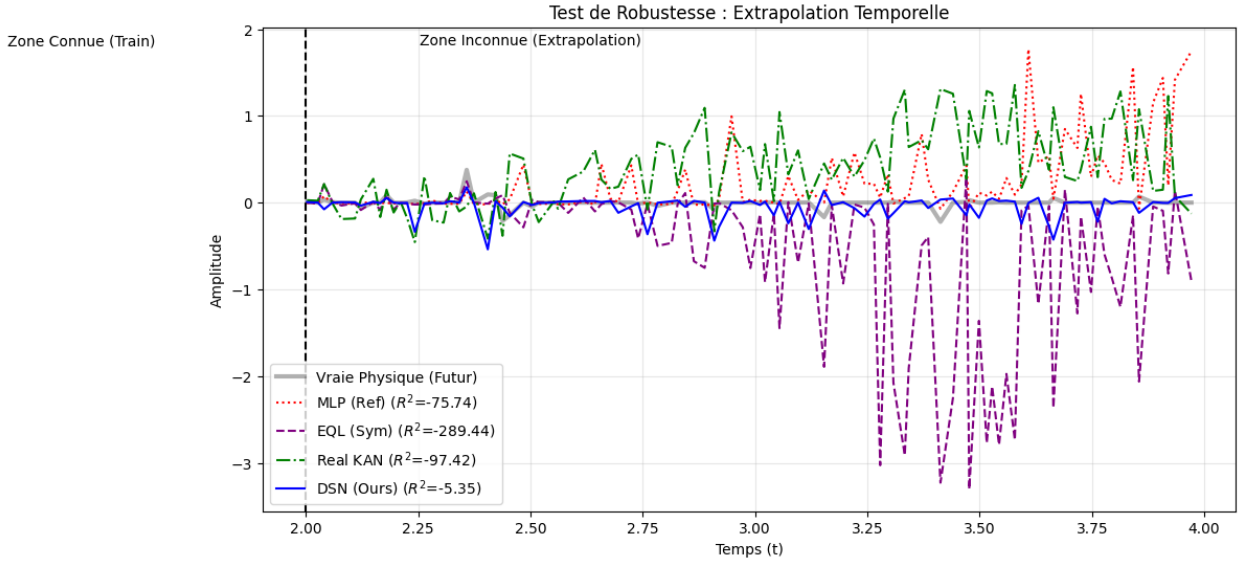



Figure 2: test2 avec une archietcure differente

### 5.5 Itérations successives des données dans le modèle : hypothèse d'attracteur

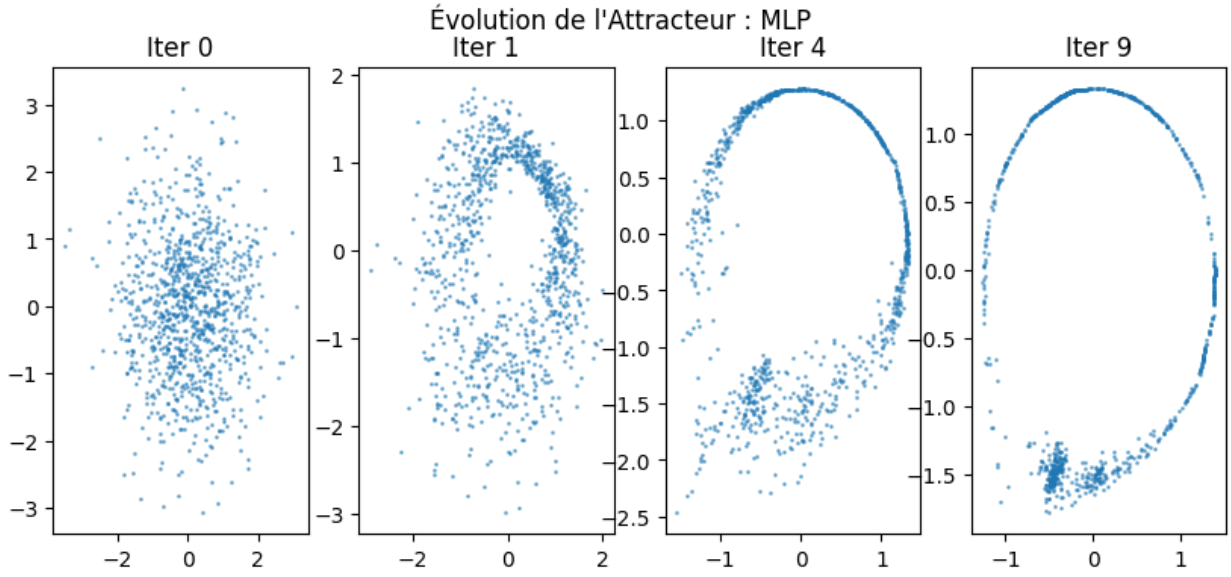



Figure 3: MLP : itérations successives à travers le modèle de données tirées aléatoirement

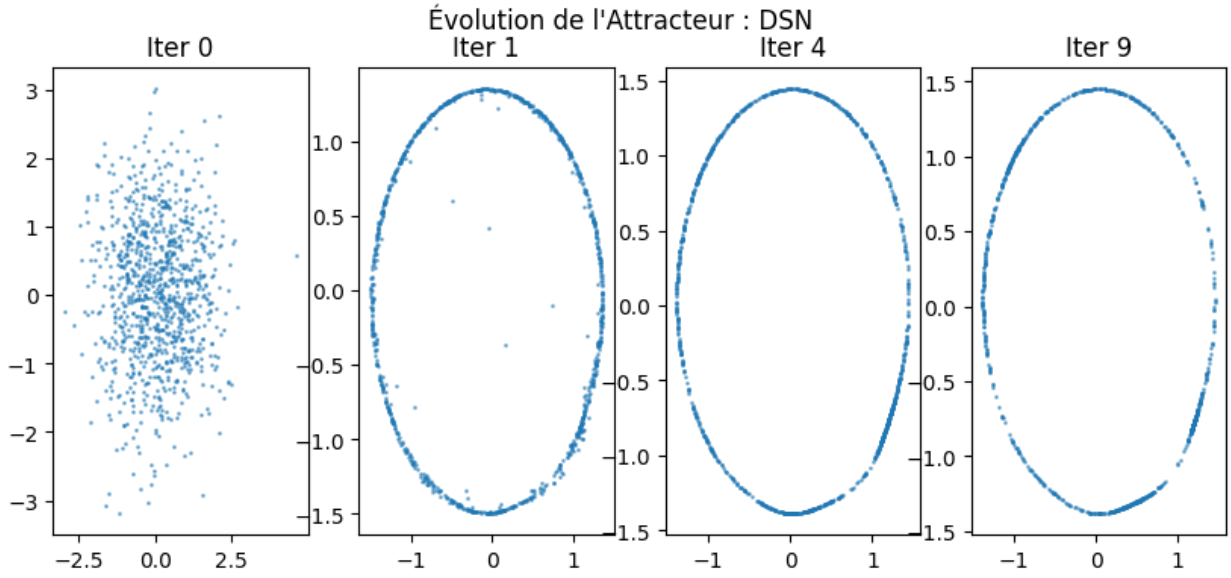



Figure 4: RAN : itérations successives à travers le modèle de données tirées aléatoirement

### 5.6 Itérations successives des données dans le modèle, Attracteur de Lorenz (Système Chaotique)

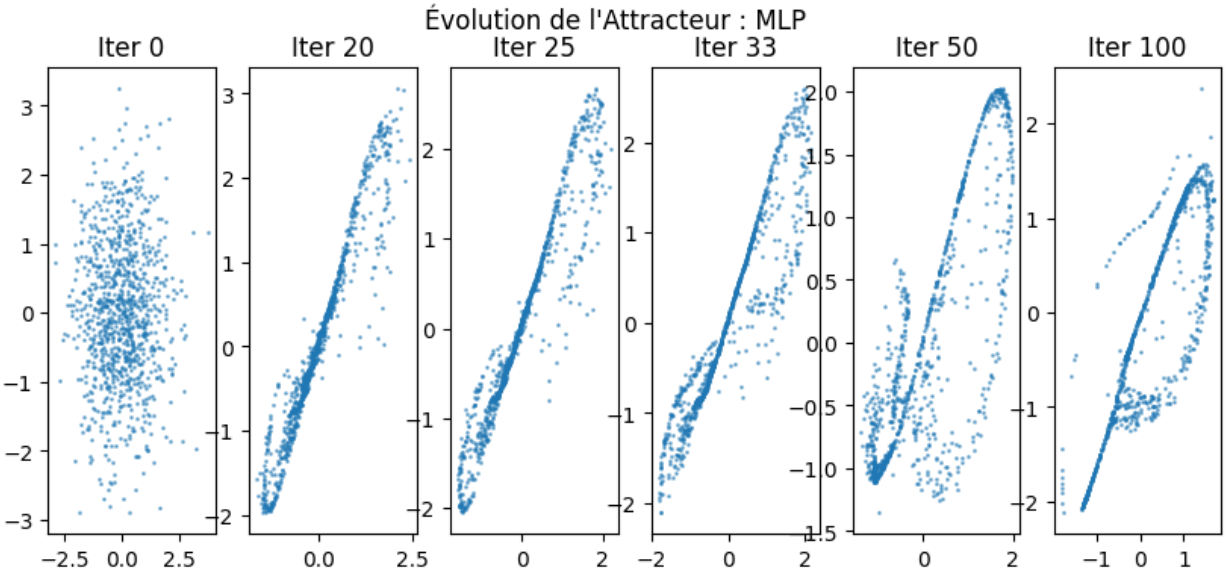



Figure 5: MLP : itérations successives à travers le modèle de données tirées aléatoirement

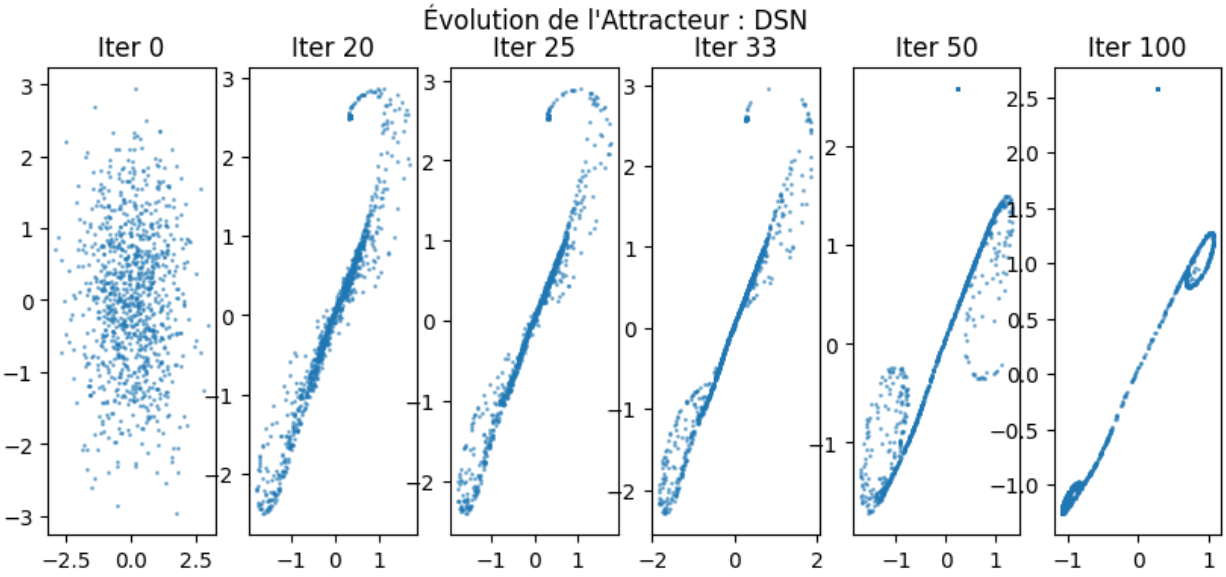



Figure 6: RAN : itérations successives à travers le modèle de données tirées aléatoirement

## 5.7 Zero-shot

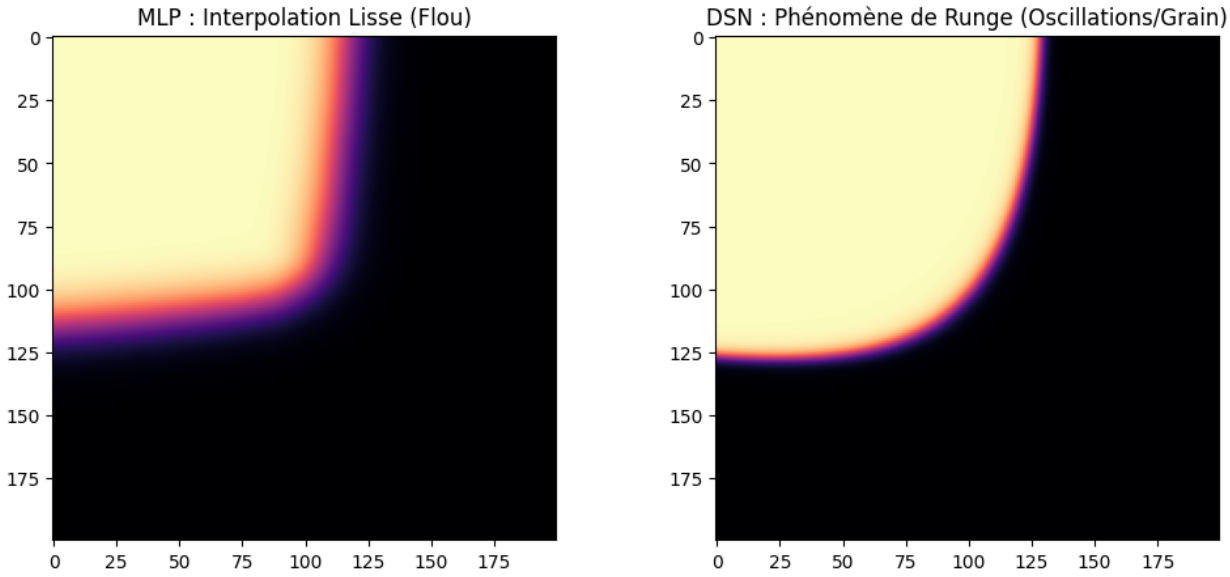



Figure 7: MLP et RAN zero-shot